

来自链接: <https://medium.com/@pdquant/all-the-backpropagation-derivatives-d5275f727f60>


By Patrick David

Machine Learning , Deep Learning, AI, Python, Quant Trading -ML

Researcher-follow for walkthroughs, tutorials, proofs, research etc. Also on twitter @pdquant

Jun 8

All the Backpropagation derivatives



$$\frac{\partial L}{\partial w} \quad \frac{\partial L}{\partial b}$$

$$\frac{\partial L}{\partial z} \quad \frac{\partial L}{\partial a}$$

All the Backprop Derivations

我们知道前馈神经网络是长这样的：

$$Z^{[1]} = W^{[1]}X + b^{[1]}$$

$$A^{[1]} = g^{[1]}(Z^{[1]})$$

$$Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]}$$

$$A^{[2]} = g^{[2]}(Z^{[2]})$$

\vdots

$$A^{[L]} = g^{[L]}(Z^{[L]}) = \hat{Y}$$

Forwardpropagation Equations

然后我们知道反向传播算法是长这样的：

$$\begin{aligned}
dZ^{[L]} &= A^{[L]} - Y \\
dW^{[L]} &= \frac{1}{m} dZ^{[L]} A^{[L]T} \\
db^{[L]} &= \frac{1}{m} np.sum(dZ^{[L]}, axis = 1, keepdims = True) \\
dZ^{[L-1]} &= dW^{[L]T} dZ^{[L]} g'^{[L]}(Z^{[L-1]}) \\
&\vdots \\
dZ^{[1]} &= dW^{[L]T} dZ^{[2]} g'^{[1]}(Z^{[1]}) \\
dW^{[1]} &= \frac{1}{m} dZ^{[1]} A^{[1]T} \\
db^{[1]} &= \frac{1}{m} np.sum(dZ^{[1]}, axis = 1, keepdims = True)
\end{aligned}$$

Backpropagation Equations

问题是你知不知道这些式子是怎样推导出来的呢？

如果你已经知道了反向传播，但是又不知道诸如

$$A - Y$$

The derivative of our linear function - dz


和

$$-\sum \left[\frac{y}{a} + \frac{(1-y)}{1-a} \right]$$

The derivative of our activation function - da

这样的式子是怎样推导出来的, 如果你希望了解直接推导或使用链式法则推导的过程, 请读下去。。。

神经网络



Neural Net taken from Coursera Deep Learning.

这是一个简单的神经网络模型，这里x, W和b是我们的输入，这里的z是这些输入的线性函数变换，这里的a是我们的激活函数（sigmoid），然后最后

$$L(a, y)$$

Cross Entropy cost function

是模型的交叉熵或负对数形式的代价函数。

我们将会从代价函数开始反向传播

$$L(a, y) = -\frac{1}{m} \left[\sum_{i=1}^m y \ln(a) + (1 - y) \ln(1 - a) \right]$$

Our cost function

然后直接进行计算，对代价函数

$$L(a, y)$$

Cross Entropy cost function

进行求导可分为如下几个部分：

$$\frac{\partial L}{\partial a} \quad \frac{\partial L}{\partial z} \quad \frac{\partial L}{\partial w} \quad \frac{\partial L}{\partial b}$$

The derivatives of $L(a, y)$ w.r.t each element in our NN

对上述导数的求解过程，本文将采用直接求解和链式法则两种方式进行讲述。

Note: we don't differentiate our input 'X' because these are fixed values that we are given and therefore don't optimize over.

注：我们不对输入'X'进行求导因为X是给定的固定的

数值，因此我们不需要在此进行求导学习

[1] 代价函数求导

$$\frac{\partial L}{\partial a}$$

[1] derivative of our activation function

首先，我们会对代价函数进行求导

$$L(a, y)$$

激活函数定义为

$$a^{[2]}$$

Activation function 2

因此我们是在对负对数形式的函数（交叉熵）进行求导，可以推导为：

$$\frac{\partial L}{\partial a} = [y \ln(a) + (1 - y) \ln(1 - a)]$$

Taking derivative of our cost function

会得到：（注：上式图像有误）

$$= \left[y \frac{1}{a} - (1 - y) \frac{1}{(1 - a)} \right]$$

derivative of cost function w.r.t 'a2'

在推导过程中，我们用到了log求导的链式法则：

$$\frac{d}{dx} [\ln g(x)] = \frac{1}{g(x)} g'(x)$$

the derivative of a log

ln(x)的导数为x的倒数的证明过程如下：

Proof for the derivative of the natural logarithm:

Let $f(x) = \ln(x)$. To be found: $f'(x) = [\ln(x)]'$.

The natural logarithm is the inverse function of the exponential function e^x , and vice versa, therefore:

$$e^{f(x)} = x$$

We differentiate both sides of the equation:

$$[e^{f(x)}]' = [x]'$$

$$e^{f(x)} \cdot f'(x) = 1$$

$$x \cdot f'(x) = 1$$

Now, we solve for $f'(x)$:

$$f'(x) = \frac{1}{x}$$

$$[\ln(x)]' = \frac{1}{x}$$

proof for the derivative of a log

重写一下上面的结果可以得到：

$$-\sum \left[\frac{y}{a} - \frac{(1-y)}{(1-a)} \right]$$

derivative of L(a,y) w.r.t a2

[2] Derivative of sigmoid

[2] 激活函数求导（sigmoid求导）

$$\frac{\partial a}{\partial z}$$

[2] derivative of sigmoid

现在我们来计算一下sigmoid激活函数的导数，后续我们将要用到它。

先来看sigmoid（logistic函数）的定义：

$$\frac{1}{1+e^{-z}}$$

Sigmoid (Logistic) function

首先将式子改写成下面的样子，方便我们使用链式法则进行微分：

$$(1 + e^{-z})^{-1}$$

Rearranged sigmoid function

然后使用链式法则：外层函数的导数与内层函数导数的乘积

$$-(1 + e^{-z})^{-2} \cdot [e^{-z} \cdot -1]$$

outer derivative x inner derivative

重写一下得到如下形式：

$$\frac{e^{-z}}{(1+e^{-z})^2}$$

put RHS over LHS

下面是一个技巧性的部分。我们将上式变成两个部分的乘积，分母都是 $1+e^{-z}$ ，第二部分的分子 e^{-z} ，我们进行加一减一的操作，得到：

$$\frac{1}{1+e^{-z}} \cdot \frac{1+(e^{-z})-1}{(1+e^{-z})}$$

add a '1' and subtract a '1' on RHS

第二部分 (RHS) 现在简化为:

$$\left[1 - \frac{1}{1+e^{-z}}\right]$$

你应该立刻发现, 上式其实就是:

$$(1 - \text{sig}(z))$$

1 minus our sigmoid

而第一部分本来就是 $\text{sig}(z)$, 因此, 整个结果就是:

$$\text{sig}(z) \cdot (1 - \text{sig}(z))$$

或者用 a 表示激活函数 (sigmoid) 时, 简化为:

$$a(1 - a)$$

This notation will be easier

[3] 线性函数求导

$$\frac{\partial L}{\partial z}$$

[3] derivative of our linear function ($z = wX + b$)

To get this result we can use chain rule by multiplying the two results we've already calculated [1] and [2]

要得到上式的导数结果, 根据链式法则我们可以将[1]和[2]乘起来

multiply derivative [1] by derivative [2]

$$- \left[\frac{y}{a} - \frac{(1 - y)}{(1 - a)} \right] \cdot a(1 - a)$$

der[1] x der[2]

通分：

$$- \left[\frac{y(1-a)}{a(1-a)} - \frac{(a)(1-y)}{(a)(1-a)} \right] \cdot a(1-a)$$

add '(1-a)' and 'a' to get common denominator

得到：（注：下图有错误，负号应移入括号中，1-y也应有括号）

$$- \left[\frac{y(1-a) + (a)1 - y}{a(1-a)} \right] \cdot a(1-a)$$

common denominator

第一部分分母和第二部分约去，得到：（注：1-y应有括号）

$$-y(1-a) + (a)1 - y$$

the remaining numerator

展开得到：

$$-y + ya + a - ay$$

expanded out

最终得到：

$$-y + a$$

所以最终我们算得

$$\frac{\partial L}{\partial z}$$

的导数是：

$$a - y$$

derivative of our linear function ($z = wX + b$)

[4] 权重值的求导

$$\frac{\partial z}{\partial w}$$

[4] derivative of linear func 'z' w.r.t weights 'w'

这个导数非常容易得到，因为z定义为：

$$W^T X + b$$

linear function 'z'

因此求导得到：

$$X$$

derivative of 'z' w.r.t 'w'

[5] 权重值求导 (2)

$$\frac{\partial L}{\partial w}$$

[5] derivative of cost func w.r.t weights 'w'

我们将采用两种方式计算这个导数，链式法则和直接计算。

链式法则：我们注意到我们已经计算了如下的导数

$$\frac{\partial L}{\partial a} \frac{\partial a}{\partial z} \frac{\partial z}{\partial w}$$

previously computed

Noting that the product of the first two equations gives us
注意到前面两项的乘积其实就是：

$$\frac{\partial L}{\partial z}$$

继续应用链式法则，我们乘上

$$\frac{\partial z}{\partial w}$$

我们将得到

$$\frac{\partial L}{\partial z} \cdot x$$

即：

$$x(a - y)$$

The final result for 'dw'

或者用链式法则写出来：

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$

chain rule result for 'dw'

下面我们直接计算这个导数，还是回到交叉熵代价函数：

$$-\sum [y \ln(a) + (1 - y) \ln(1 - a)]$$

Cross Entropy cost function

展开第一个log项，代入激活函数得到：

$$\ln(1 + e^{-z})^{-1}$$

expanding 'ln(a)'

即：

$$-\ln(1 + e^{-z})$$

展开第二个log项，带入激活函数得到：

$$\ln \frac{e^{-z}}{(1 + e^{-z})}$$

ln(1-a)

由log运算法则可得：

$$(-z - \ln(1 + e^{-z}))$$

log of the numerator

将上面两个中间结果代入到原来的代价函数得到：

$$\sum -y \ln(1 + e^{-z}) [(1 - y)(-z - \ln(1 + e^{-z}))]$$

1*od0TgKCRaIB_rbL0rmqkUA.png

plugged back into cost function

将中括号中的乘法进行多项式展开，得到：

$$\sum -y \ln(1 + e^{-z}) - z - \ln(1 + e^{-z}) + yz + y \ln(1 + e^{-z})$$

terms inside bracket expanded

消去第一项和最后一项，得到：

$$-z - \ln(1 + e^{-z}) + yz$$

重写一下顺序：

$$yz - [z + \ln(1 + e^{-z})]$$

这里又有一个小技巧，对中括号的第一项z进行求幂然后求对数操作，得到：

$$yz - [\ln(e^z) + \ln(1 + e^{-z})]$$

we exponentiate 'e^z' then take its log

next we can take advantage of the rule of sum of logs: $\ln(a) + \ln(b) = \ln(a.b)$ combined with rule of exp products: $e^a + e^b = e^{(a+b)}$ to get

运用log运算规则，得到：（注：中括号中的第一个加号应为乘号）

$$yz - [\ln((e^z) + (1 + e^{-z}))]$$

summing the logs

然后得到：

$$yz - [\ln(1 + e^z)]$$

summing the exps

重写得到：

$$[yz - \ln(1 + e^z)]$$

最终我们得到代价函数对权重W的偏导数为：

$$\frac{\partial L}{\partial w} [yz - \ln(1 + e^z)]$$

take derivative w.r.t W

第一项yz变为yx，应用链式法则计算第二项后，得到：

$$yx - \frac{x \cdot e^{wx}}{1 + e^{wx}}$$

taking derivative of logs again

根据激活函数的定义，实际上第二项就是：

$$x \cdot \text{sig}(z)$$

代入后得到：

$$- [yx - x \cdot \text{sig}(z)]$$

将x因子提出来：

$$-x [y - \text{sig}(z)]$$

最终得到：

$$\frac{\partial L}{\partial w} = x [a - y]$$

final result

[6] 偏置项的导数

$$\frac{\partial L}{\partial b}$$

[6] derivative w.r.t bias b

我们还是可以采用链式法则：

$$\frac{\partial L}{\partial z} \cdot \frac{\partial z}{\partial b}$$

chain rule for 'db'

这个是非常容易计算的，因为 $z=wx+b$ 对 b 的偏导数就是1，因此结果就是代价函数对 z 的偏导数：

$$\frac{\partial L}{\partial z}$$

这个值我们前面已经计算得到：

$$a - y$$

derivative of our linear function ($z = wx + b$)

这里我们同样使用直接计算推导偏置项的导数。这里我们用到前面算权重值导数时的中间结果：

$$[yz - \ln(1 + e^z)]$$

note: $z = wx + b$

将 $z=wx+b$ 代入上式，得到

$$\frac{\partial L}{\partial b} y(wx + b) - \frac{\partial L}{\partial b} \ln(1 + e^{wx+b})$$

0*VgWLH92SBmRefdWY

note the parenthesis

左边求导得到 y ，因为第一项不含 b ，右边求导得到：

$$\frac{e^{wx+b}}{1 + e^{wx+b}}$$

derivative of $\ln(1+e^{wx+b})$

分子分母同除 $e^{(wx+b)}$ ，就可以得到激活函数（sigmoid），即：

a

左右组合在一起得到

$$[a - y]$$

final result

其实就是代价函数对 z 的偏导数：

$$\frac{\partial L}{\partial z}$$

'db' = 'dz'

这样我们就推到了神经网络的所有导数。我们计算了一下所有的偏导数：

$$\frac{\partial L}{\partial a} \frac{\partial L}{\partial z} \frac{\partial L}{\partial w} \frac{\partial L}{\partial b}$$

The derivatives of $L(a,y)$ w.r.t each element in our NN
